


# Sistemas Operacionais GT 08 - Trilha A - Ollama + OpenWebUI

- O objetivo do estudo é nortear quais as relações de configuração do modelo, camada de aplicação, quantização e parâmetros influenciam os recursos computacionais do SO.
- Arquitetura é composta pela Windows System Linux para a instalação do linux.
- Hardware utilizado: WSL2, Ubuntu 26.04, Kernel 6.18, CPU XEON, 16GB ram e RTX 3060 de 12 giga CUDA.




*Mini arquitetura do projeto*

## Modelo Escolhido: - Granite 3.1 - 3B - A800M - Instruct

---

- Modelo pequeno com grande potência.
- Arquitetura MoE ( Mixture of Experts ), com subdivisões em suas redes neurais contendo redes experts em diferentes problemas.
- Modelo que performou de forma consistente em diferentes máquinas dos membros do grupo por conta disso.



# Metodologia escolhida e obtenção das métricas.

---

## Realização de 3 configurações experimentais.

1. Execução Padrão, utilizando cinco perguntas enviadas sequencialmente, uma por vez.
2. A segunda foi teste de concorrência, em que enviamos requisições de 2 até 12 requisições simultâneas, aumentando a unidade de tempo.
3. Comparação direta entre CPU e GPU, mantendo o mesmo modelo e deixando somente a disponibilidade da CPU




# Metodologia escolhida e obtenção das métricas.

---

## Coleta de Métricas

- Para realizar as medições, utilizamos scripts em Python para controlar e cronometrar as requisições.
- utilizamos o docker stats para CPU e memória, o nvidia-smi para GPU e VRAM, além do ps e lsof e do strace para analisar processos, threads e chamadas de sistema.



## O escalonador do Linux distribui cada uma dessas threads entre os núcleos do processador

|  | 1  | UID  | PID | PPID | LWP | C  | NLWP | STIME | TTY | TIME     | CMD               |
|--|----|------|-----|------|-----|----|------|-------|-----|----------|-------------------|
|  | 2  | root | 1   | 0    | 1   | 0  | 35   | 20:57 | ?   | 00:00:02 | /bin/ollama serve |
|  | 3  | root | 1   | 0    | 8   | 0  | 35   | 20:57 | ?   | 00:00:06 | /bin/ollama serve |
|  | 4  | root | 1   | 0    | 9   | 0  | 35   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 5  | root | 1   | 0    | 10  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 6  | root | 1   | 0    | 11  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 7  | root | 1   | 0    | 12  | 0  | 35   | 20:57 | ?   | 00:00:00 | /bin/ollama serve |
|  | 8  | root | 1   | 0    | 13  | 0  | 35   | 20:57 | ?   | 00:00:00 | /bin/ollama serve |
|  | 9  | root | 1   | 0    | 14  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 10 | root | 1   | 0    | 15  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 11 | root | 1   | 0    | 16  | 0  | 35   | 20:57 | ?   | 00:00:00 | /bin/ollama serve |
|  | 12 | root | 1   | 0    | 17  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 13 | root | 1   | 0    | 18  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 14 | root | 1   | 0    | 34  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 15 | root | 1   | 0    | 35  | 0  | 35   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 16 | root | 1   | 0    | 47  | 0  | 35   | 20:57 | ?   | 00:00:02 | /bin/ollama serve |
|  | 17 | root | 1   | 0    | 102 | 0  | 35   | 21:01 | ?   | 00:00:04 | /bin/ollama serve |
|  | 18 | root | 1   | 0    | 103 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 19 | root | 1   | 0    | 104 | 0  | 35   | 21:01 | ?   | 00:00:04 | /bin/ollama serve |
|  | 20 | root | 1   | 0    | 105 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 21 | root | 1   | 0    | 106 | 0  | 35   | 21:01 | ?   | 00:00:02 | /bin/ollama serve |
|  | 22 | root | 1   | 0    | 107 | 0  | 35   | 21:01 | ?   | 00:00:05 | /bin/ollama serve |
|  | 23 | root | 1   | 0    | 108 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 24 | root | 1   | 0    | 109 | 0  | 35   | 21:01 | ?   | 00:00:12 | /bin/ollama serve |
|  | 25 | root | 1   | 0    | 110 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 26 | root | 1   | 0    | 111 | 0  | 35   | 21:01 | ?   | 00:00:01 | /bin/ollama serve |
|  | 27 | root | 1   | 0    | 112 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 28 | root | 1   | 0    | 113 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 29 | root | 1   | 0    | 114 | 0  | 35   | 21:01 | ?   | 00:00:04 | /bin/ollama serve |
|  | 30 | root | 1   | 0    | 115 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 31 | root | 1   | 0    | 116 | 0  | 35   | 21:01 | ?   | 00:00:02 | /bin/ollama serve |
|  | 32 | root | 1   | 0    | 117 | 0  | 35   | 21:01 | ?   | 00:00:03 | /bin/ollama serve |
|  | 33 | root | 1   | 0    | 118 | 0  | 35   | 21:01 | ?   | 00:00:02 | /bin/ollama serve |
|  | 34 | root | 1   | 0    | 119 | 0  | 35   | 21:01 | ?   | 00:00:04 | /bin/ollama serve |
|  | 35 | root | 1   | 0    | 120 | 0  | 35   | 21:01 | ?   | 00:00:02 | /bin/ollama serve |
|  | 36 | root | 1   | 0    | 121 | 0  | 35   | 21:02 | ?   | 00:00:02 | /bin/ollama serve |
|  | 37 | root | 251 | 0    | 251 | 75 | 1    | 21:26 | ?   | 00:00:00 | ps -eLf           |


ollama-cpu - 35 threads

|  | 1  | UID  | PID | PPID | LWP | C  | NLWP | STIME | TTY | TIME     | CMD               |
|--|----|------|-----|------|-----|----|------|-------|-----|----------|-------------------|
|  | 2  | root | 1   | 0    | 1   | 0  | 36   | 20:57 | ?   | 00:00:01 | /bin/ollama serve |
|  | 3  | root | 1   | 0    | 27  | 0  | 36   | 20:57 | ?   | 00:00:07 | /bin/ollama serve |
|  | 4  | root | 1   | 0    | 28  | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 5  | root | 1   | 0    | 29  | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 6  | root | 1   | 0    | 30  | 0  | 36   | 20:57 | ?   | 00:00:02 | /bin/ollama serve |
|  | 7  | root | 1   | 0    | 31  | 0  | 36   | 20:57 | ?   | 00:00:00 | /bin/ollama serve |
|  | 8  | root | 1   | 0    | 32  | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 9  | root | 1   | 0    | 33  | 0  | 36   | 20:57 | ?   | 00:00:00 | /bin/ollama serve |
|  | 10 | root | 1   | 0    | 34  | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 11 | root | 1   | 0    | 35  | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 12 | root | 1   | 0    | 36  | 0  | 36   | 20:57 | ?   | 00:00:02 | /bin/ollama serve |
|  | 13 | root | 1   | 0    | 37  | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 14 | root | 1   | 0    | 38  | 0  | 36   | 20:57 | ?   | 00:00:05 | /bin/ollama serve |
|  | 15 | root | 1   | 0    | 41  | 0  | 36   | 20:57 | ?   | 00:00:10 | /bin/ollama serve |
|  | 16 | root | 1   | 0    | 45  | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 17 | root | 1   | 0    | 46  | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 18 | root | 1   | 0    | 228 | 0  | 36   | 20:57 | ?   | 00:00:01 | /bin/ollama serve |
|  | 19 | root | 1   | 0    | 229 | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 20 | root | 1   | 0    | 230 | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 21 | root | 1   | 0    | 231 | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 22 | root | 1   | 0    | 232 | 0  | 36   | 20:57 | ?   | 00:00:02 | /bin/ollama serve |
|  | 23 | root | 1   | 0    | 233 | 0  | 36   | 20:57 | ?   | 00:00:01 | /bin/ollama serve |
|  | 24 | root | 1   | 0    | 234 | 0  | 36   | 20:57 | ?   | 00:00:00 | /bin/ollama serve |
|  | 25 | root | 1   | 0    | 235 | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 26 | root | 1   | 0    | 236 | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 27 | root | 1   | 0    | 237 | 0  | 36   | 20:57 | ?   | 00:00:04 | /bin/ollama serve |
|  | 28 | root | 1   | 0    | 238 | 0  | 36   | 20:57 | ?   | 00:00:02 | /bin/ollama serve |
|  | 29 | root | 1   | 0    | 239 | 0  | 36   | 20:57 | ?   | 00:00:05 | /bin/ollama serve |
|  | 30 | root | 1   | 0    | 240 | 0  | 36   | 20:57 | ?   | 00:00:05 | /bin/ollama serve |
|  | 31 | root | 1   | 0    | 241 | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 32 | root | 1   | 0    | 242 | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 33 | root | 1   | 0    | 243 | 0  | 36   | 20:57 | ?   | 00:00:03 | /bin/ollama serve |
|  | 34 | root | 1   | 0    | 244 | 0  | 36   | 20:57 | ?   | 00:00:06 | /bin/ollama serve |
|  | 35 | root | 1   | 0    | 245 | 0  | 36   | 20:58 | ?   | 00:00:03 | /bin/ollama serve |
|  | 36 | root | 1   | 0    | 246 | 0  | 36   | 20:58 | ?   | 00:00:03 | /bin/ollama serve |
|  | 37 | root | 1   | 0    | 247 | 0  | 36   | 20:58 | ?   | 00:00:01 | /bin/ollama serve |
|  | 38 | root | 549 | 0    | 549 | 50 | 1    | 21:26 | ?   | 00:00:00 | ps -eLf           |


ollama-gpu - 36 threads

# Uso de CPU e Memória

Uso de CPU do container (pico) por nível de concorrência



Uso de memória do container (pico) por nível de concorrência



CPU consome bem mais RAM porque precisa guardar o modelo inteiro ali.

# Uso da GPU e STRACE

Mon Sep 14 18:29:02 2026

|                      |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
|----------------------|-------------------------|---------------|---------------------|--------------------|---------------|------------------------|----------|------------|--|--|--|--|--|--|--|--|--|--|--|--|
| -----+-----          |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| NVIDIA-SMI 615.65.07 |                         |               | KMD Version: 616.64 |                    |               | CUDA UMD Version: 13.4 |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| -----+-----          |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| GPU Name             |                         | Persistence-M |                     | Bus-Id             | Disp.A        | Volatile Uncorr. ECC   |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| Fan                  | Temp                    | Perf          | Pwr:Usage/Cap       |                    | Memory-Usage  |                        | GPU-Util | Compute M. |  |  |  |  |  |  |  |  |  |  |  |  |
|                      |                         |               |                     |                    |               | MIG M.                 |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| =====+=====          |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| 0                    | NVIDIA GeForce RTX 3060 |               | On                  | 00000000:03:00.0   |               | On                     | N/A      |            |  |  |  |  |  |  |  |  |  |  |  |  |
| 30%                  | 47C                     | P2            | 103W / 170W         | 3375MiB / 12288MiB |               | 60%                    | Default  |            |  |  |  |  |  |  |  |  |  |  |  |  |
|                      |                         |               |                     |                    |               | N/A                    |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| -----+-----          |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| -----+-----          |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| Processes:           |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| GPU                  | GI                      | CI            | PID                 | Type               | Process name  | GPU Memory             |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
|                      |                         | ID ID         |                     |                    |               | Usage                  |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| =====+=====          |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| 0                    | N/A                     | N/A           | 26                  | G                  | /Xwayland     | N/A                    |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| 0                    | N/A                     | N/A           | 591                 | C                  | /llama-server | N/A                    |          |            |  |  |  |  |  |  |  |  |  |  |  |  |
| -----+-----          |                         |               |                     |                    |               |                        |          |            |  |  |  |  |  |  |  |  |  |  |  |  |


| % time | seconds  | usecs/call | calls | errors | syscall         |
|--------|----------|------------|-------|--------|-----------------|
| -----  |          |            |       |        |                 |
| 74.16  | 0.232180 | 1967       | 118   | 6      | futex           |
| 10.11  | 0.031645 | 169        | 187   |        | nanosleep       |
| 7.86   | 0.024614 | 219        | 112   |        | epoll_pwait     |
| 3.09   | 0.009674 | 93         | 103   | 48     | read            |
| 2.89   | 0.009058 | 164        | 55    |        | write           |
| 0.74   | 0.002320 | 210        | 11    |        | sched_yield     |
| 0.73   | 0.002284 | 1142       | 2     |        | tgkill          |
| 0.18   | 0.000571 | 285        | 2     |        | getpid          |
| 0.15   | 0.000469 | 234        | 2     |        | rt_sigreturn    |
| 0.09   | 0.000275 | 275        | 1     | 1      | restart_syscall |
| -----  |          |            |       |        |                 |
| 100.00 | 0.313090 | 527        | 593   | 55     | total           |

O sistema operacional está o tempo todo escalonando threads, gerenciando memória e arbitrando o acesso à GPU




## GPU reduz o tempo e aumenta a velocidade de geração

Média de cinco perguntas, uma requisição por vez.



**GPU: 3,81× menos tempo**





**GPU: 3,99× mais tokens/s**

*Leitura: no mesmo modelo e prompt, a GPU entrega uma resposta perceptivelmente mais rápida.*



## Mais requisições simultâneas aumentam a latência

Cada ponto representa uma carga concorrente com 2, 4, 6 ou 12 requisições.





**A GPU permanece mais rápida, mas a fila cresce quando há mais usuários concorrentes.**

*0 falhas observadas em todas as cargas • Limitação: uma execução por nível de concorrência.*

# A concorrência pressiona CPU e memória

Picos observados no contêiner do Ollama durante os testes concorrentes.



GPU observada: RTX 3060 a 60% de uso, com 3.375 MiB de VRAM ocupada.

**Conclusão:** neste ambiente, a GPU oferece a melhor responsividade; sob concorrência, porém, CPU de suporte, memória e filas ainda limitam o desempenho.

# Tabela de Conclusões

Análise de IA Generativa Local (Ollama + OpenWebUI)

| Tópico Chave                         | Explicação Breve                                                                                                                                                                     |
|--------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Desempenho Geral (GPU vs CPU)        | A GPU se mostrou quase 4x mais rápida, reduzindo o tempo de resposta e processando muito mais tokens por segundo do que a CPU.                                                       |
| Consumo de Recursos (Memória e CPU)  | A versão em CPU consome significativamente mais memória RAM e núcleos de processamento, pois precisa alocar todo o modelo e esforço no sistema principal.                            |
| Gerenciamento do Sistema Operacional | O SO gasta a maior parte do tempo (cerca de 74%) organizando e sincronizando as <i>threads</i> (futex). A GPU alivia esse fardo atuando como um recurso dedicado.                    |
| Impacto da Concorrência              | Com múltiplas requisições simultâneas, a latência aumenta em ambos os cenários. Porém, a GPU mantém o tempo de resposta muito mais sob controle, enquanto a CPU gargala rapidamente. |